



UJED

UNIVERSIDAD JUÁREZ DEL
ESTADO DE DURANGO



Proyecto de Minería de Datos aplicando CRISP-DM

MAESTRÍA EN
ESTADÍSTICA APLICADA,
3ER SEMESTRE

Catedrático:
Dr. Gerónimo Quiñonez Barraza

ALUMNO: JESÚS FELICIANO GAMERO MORGAN

febrero 2026

Introducción

En estudios socioeconómicos y políticas públicas, es relevante identificar los factores que influyen en el nivel de ingresos de la población. La capacidad de predecir si una persona pertenece a un grupo de ingresos altos (más de 50,000 USD anuales) permite:

- Diseñar políticas fiscales más eficientes
- Optimizar estrategias de mercado
- Identificar brechas socioeconómicas
- Analizar patrones demográficos relevantes



El dataset que se trabaja en este ejercicio (Adult Dataset), proviene del censo de Estados Unidos y contiene información demográfica, educativa y laboral de aproximadamente 48,000 individuos.

(Fuente: UCI Machine Learning Repository)

Crisp-DM

De acuerdo con esta metodología de análisis de datos, iniciamos con:

1. Comprensión del negocio.

¿**Cuál es el problema?**

Predecir a partir de variables demográficas y laborales si un individuo pertenece al grupo de ingresos mayores de 50,000 dls. Anuales.

Objetivo de resolver el problema:

Construir y evaluar **modelos de aprendizaje supervisado** (datos etiquetados) que permitan clasificar correctamente el nivel de ingreso de un individuo utilizando variables socioeconómicas disponibles en este data set (Adult dataset).



Crisp-DM → **1. Comprensión del negocio.**

Durante el desarrollo del proyecto se...

1. Analizarán exploratoriamente las variables del dataset.
2. Prepararán los datos mediante limpieza, codificación y escalamiento.
3. Construirán múltiples modelos de clasificación.
4. Comparará el desempeño mediante métricas apropiadas.
5. Identificarán las variables con mayor impacto en la predicción.
6. Propondrá una posible implementación del modelo en un entorno real.



Crisp-DM → **1. Comprensión del negocio.**

Alcance del proyecto:

- Se trabajará exclusivamente con los datos disponibles en el dataset.
- Es decir, no se incorporarán variables externas.
- El enfoque será clasificación binaria.
- Se evaluará desempeño.

Relevancia:

El proyecto se considerará exitoso si:


- Se alcanza una buena **precisión** ($> 85\%$).
- El modelo muestra **estabilidad** entre entrenamiento y prueba.
- Se identifican **variables relevantes** interpretables.



Crisp-DM → **1. Comprensión del negocio.**

Algunas preguntas clave:

- ¿Qué variables influyen más en el nivel de ingreso?
- ¿La educación es el factor dominante?
- ¿Existen patrones asociados al estado civil?
- ¿El género influye significativamente?



Crisp-DM → **2. Comprensión de los datos.**

En esta fase:

- Carga los **datos**
- **Exploración**
- Tipos de **variables**
- **Estadísticos** descriptivos
- Distribución de **clases**
- Valores **faltantes**



Crisp-DM → **3. Preparación de los datos.**

En esta fase:


- Tratamiento de valores **faltantes**
- **Limpieza** de espacios en variable objetivo
- Codificación de **variable objetivo**
- Separación de **variables predictoras** y objetivo
- Codificación de **variables categóricas**
- **Escalamiento** de variables
- División en **training / validation / test**
- **Verificación** final



Crisp-DM → **4. Modelación.**

En esta fase:


- Construir varios modelos
- Compararlos
- Elegir el mejor



Crisp-DM → **5. Evaluación.**

En esta fase:

- Comparación **Train** vs **Test**



Crisp-DM → 6. Implementación.


Objetivo del despliegue:

El modelo desarrollado en este ejercicio, nos permite predecir si un individuo pertenece al grupo de ingresos superiores a 50,000 usd anuales, con base en variables demográficas y laborales.

Este modelo se integraría a un entorno donde pueda ser utilizado en la toma de decisiones, por ejemplo:

- En **instituciones financieras**: para evaluar riesgos, identificar perfiles, segmentar clientes financieros, etc.
- **Investigaciones socioeconómicas**: para analizar desigualdades, diseñar políticas públicas, evaluar impactos de la educación en cuanto a ingresos, etc.

Es un modelo adaptable a nuestro entorno, ya que las variables son altamente adaptables a nuestras situaciones socioeconómicas.



Crisp-DM → **7. Interpretación de resultados**


En términos generales, el mejor modelo: Random Forest


Tiene el mayor Accuracy (85.26%)

Tiene el mejor F1-score (0.6858)

Tiene el mejor Recall (0.6465)

El F1-score es clave porque el dataset está moderadamente desbalanceado.
Random Forest logra el mejor equilibrio entre precision y recall.





Crisp-DM → 8. Conclusiones

El proyecto desarrolló un modelo de clasificación supervisada para predecir el nivel de ingreso anual (>50K USD) utilizando variables demográficas y laborales, siguiendo la metodología CRISP-DM.

Los resultados mostraron un desempeño satisfactorio, con un criterio de éxito establecido (aprox. 85% de precisión) y manteniendo estabilidad entre entrenamiento y prueba, lo que indica adecuada capacidad de generalización.

El análisis de importancia de variables destacó el papel del nivel educativo, las ganancias de capital y las horas trabajadas como factores clave en la predicción del ingreso.

Se verificó la relevancia de una preparación adecuada de datos y la comparación objetiva de algoritmos para seleccionar el modelo óptimo.

Crisp-DM → **8. Recomendaciones**

- Realizar **optimización de hiperparámetros** para mejorar el desempeño del modelo.
- Implementar técnicas de análisis de equidad (fairness) para **evaluar posibles sesgos** asociados a variables sensibles como género o raza.
- **Explorar modelos más avanzados** como Gradient Boosting, XGBoost o LightGBM para comparar mejoras en capacidad predictiva.
- **Incorporar datos más recientes** o variables adicionales (por ejemplo, experiencia laboral detallada o región económica) para enriquecer el análisis.
- Establecer un esquema de **monitoreo periódico** en caso de despliegue real, debido a que las condiciones socioeconómicas cambian con el tiempo.

Crisp-DM → 9. Referencias

Chapman, P., Clinton, J., Kerber, R., Khabaza, T., Reinartz, T., Shearer, C., & Wirth, R. (2000). *CRISP-DM 1.0: Step-by-step data mining guide*. SPSS Inc.

Wirth, R., & Hipp, J. (2000). CRISP-DM: Towards a standard process model for data mining. *Proceedings of the 4th International Conference on the Practical Applications of Knowledge Discovery and Data Mining*, 29–39.

